



파머완 11주차

▼ Chapter 7. 군집화

▼ 1. K-평균 알고리즘 이해


K-평균: 군집 중심점이라는 특정한 임의의 지점을 선택해 해당 중심에 가장 가까운 포인트들을 선택하는 군집화 기법

군집화에서 가장 일반적으로 사용됨

군집 중심점

선택된 포인트의 평균 지점으로 이동 → 이동된 중심점에서 다시 가까운 포인트를 선택 → 다시 중심점을 평균 지점으로 이동

모든 데이터 포인트에서 더 이상 중심점의 이동이 없을 경우에 반복을 멈추고 해당 중심점에 속하는 데이터 포인트들을 군집화



장점: 일반적인 군집화에서 많이 활용, 알고리즘 쉽고 간결

단점: 속성의 개수가 많을 경우 군집화 정확도 떨어짐, 수행시간 느림, 군집 개수 선택 어려움

▼ 사이킷런 KMean 클래스 소개

중요 파라미터

- `n_clusters`: 군집화할 개수, 군집 중심점의 개수
- `init`: 초기에 군집 중심점의 좌표를 설정할 방식
- `max_iter`: 최대 반복 횟수

fit(), fit_transform() 메서드 이용

주요 속성 정보

- labels_: 각 데이터 포인트가 속한 군집 중심점 레이블
- cluster_centers_: 각 군집 중심점 좌표 → 군집 중심점 좌표가 어디인지 시각화

▼ 군집화 알고리즘 테스트를 위한 데이터 생성


- **make_blobs()**: 개별 군집의 중심점과 표준 편차 제어 기능 있음

호출 파라미터: n_samples, n_features, centers, cluster_std

- n_samples: 생성할 총 데이터의 개수입니다. 디폴트는 100개입니다.
- n_features: 데이터의 피쳐 개수입니다. 시각화를 목표로 할 경우 2개로 설정해 보통 첫 번째 피쳐는 x 좌표, 두 번째 피쳐는 y 좌표상에 표현합니다.
- centers: int 값, 예를 들어 3으로 설정하면 군집의 개수를 나타냅니다. 그렇지 않고 ndarray 형태로 표현할 경우 개별 군집 중심점의 좌표를 의미합니다.
- cluster_std: 생성될 군집 데이터의 표준 편차를 의미합니다. 만일 float 값 0.8과 같은 형태로 지정하면 군집 내에서 데이터가 표준편차 0.8을 가진 값으로 만들어집니다. [0.8, 1.2, 0.6]과 같은 형태로 표현되면 3개의 군집에서 첫 번째 군집 내 데이터의 표준편차는 0.8, 두 번째 군집 내 데이터의 표준 편차는 1.2, 세 번째 군집 내 데이터의 표준편차는 0.6으로 만듭니다. 군집별로 서로 다른 표준 편차를 가진 데이터 세트를 만들 때 사용합니다.

cluster_std 파라미터로 데이터의 분포도 조절

→ 작을수록 군집 중심에 데이터가 모여있음



- **make_classification()**: 노이즈를 포함한 데이터를 만드는 데 유용하게 사용할 수 있음

▼ 2. 군집 평가


실루엣 분석

각 군집 간의 거리가 얼마나 효율적으로 분리돼 있는지를 나타냄

실루엣 계수

- 개별 데이터가 가지는 군집화 지표

- 같은 군집 내의 데이터와 얼마나 가깝게 군집화돼 있고, 다른 군집에 있는 데이터와는 얼마나 멀리 분리돼 있는지 나타냄



i 번째 데이터 포인트의 실루엣 계수 값 $s(i)$

$$s(i) = \frac{(b(i) - a(i))}{(\max(a(i), b(i)))}$$

$a(i)$: 같은 군집 내에 있는 다른 데이터 포인트와의 거리를 평균한 값

$b(i)$: 속하지 않은 군집 중 가장 가까운 군집과의 평균 거리

-1 ~ 1 사이의 값

1: 다른 군집과 멀리 떨어져 있음 / 0: 근처 군집과 가까움 / - 값: 다른 군집

사용 메서드

- `sklearn.metrics.silhouette_samples(X, labels, metric='euclidean', **kwargs)`: 인자로 X feature 데이터 세트와 각 피쳐 데이터 세트가 속한 군집 레이블 값인 labels 데이터를 입력해주면 각 데이터 포인트의 실루엣 계수를 계산해 반환합니다.
- `sklearn.metrics.silhouette_score(X, labels, metric='euclidean', sample_size=None, **kwargs)`: 인자로 X feature 데이터 세트와 각 피쳐 데이터 세트가 속한 군집 레이블 값인 labels 데이터를 입력해주면 전체 데이터의 실루엣 계수 값을 평균해 반환합니다. 즉, `np.mean(silhouette_samples())`입니다. 일반적으로 이 값이 높을수록 군집화가 어느 정도 잘 됐다고 판단할 수 있습니다. 하지만 무조건 이 값이 높다고 해서 군집화가 잘 됐다고 판단할 수는 없습니다.

좋은 군집화의 조건


1. 전체 실루엣 계수의 평균값, 즉 사이킷런의 `silhouette_score()` 값은 0 ~ 1 사이의 값을 가지며, 1에 가까울수록 좋습니다.
2. 하지만 전체 실루엣 계수의 평균값과 더불어 개별 군집의 평균값의 편차가 크지 않아야 합니다. 즉, 개별 군집의 실루엣 계수 평균값이 전체 실루엣 계수의 평균값에서 크게 벗어나지 않는 것이 중요합니다. 만약 전체 실루엣 계수의 평균값은 높지만, 특정 군집의 실루엣 계수 평균값만 유난히 높고 다른 군집들의 실루엣 계수 평균값은 낮으면 좋은 군집화 조건이 아닙니다.

▼ 군집별 평균 실루엣 계수의 시각화를 통한 군집 개수 최적화 방법

개별 군집별로 적당히 분리된 거리를 유지하면서도 군집 내의 데이터가 서로 뭉쳐 있는 경우가 좋음

여러 개의 군집 개수가 주어졌을 때 이를 분석한 도표를 참고해 평균 실루엣 계수로 군집 개수를 최적화하는 방법

• 군집이 2개인 경우



군집이 2개일 경우 평균 실루엣 계수 값: 0.704


X축: 실루엣 계수 값

Y축: 개별 군집과 이에 속하는 데이터

→ 1번 군집의 모든 데이터는 평균 실루엣 계수 값 이상

→ 2번 군집의 경우는 평균보다 적은 데이터 값이 매우 많음

• 군집이 3개인 경우




군집이 3개일 경우 평균 실루엣 계수 값: 0.588

→ 1번, 2번 군집은 평균보다 높은 실루엣 계수 값

→ 0번은 평균보다 낮음: 내부 데이터 간 거리도 멀고 2번 군집과 가깝게 위치

• 군집이 4개인 경우



군집이 4개일 경우 평균 실루엣 계수 값: 0.65

→ 모든 데이터가 평균보다 높은 계수 값을 가지고 있음

→ 군집이 2개인 경우보다는 평균 실루엣 계수 값이 작지만 가장 이상적

데이터 양이 늘어나면 수행 시간이 크게 늘어남

→ 군집별로 임의의 데이터를 샘플링해 실루엣 계수를 평가해야함

▼ 3. 평균 이동

평균 이동


- K-평균과 유사하게 중심을 군집의 중심으로 지속적으로 움직이면서 군집화 수행

- 데이터가 모여 있는 밀도가 가장 높은 곳으로 이동시킴

군집 중심점

- 데이터 포인트가 모여있는 곳이라는 생각에서 착안, 확률 밀도 함수 이용
- 가장 집중적으로 데이터가 모여있어 확률 밀도 함수가 피크인 점
- KDE (Kernel Density Estimation) 이용

주변 데이터와의 거리 값을 KDE 함수로 입력한 뒤 그 반환 값을 현재 위치에서 업데이트하면서 이동




KDE (Kernel Density Estimation)

- Kernel 함수를 통해 어떤 변수의 확률 밀도 함수를 추정하는 대표적인 방법
- 관측된 데이터 각각에 커널 함수를 적용한 값을 모두 더한 뒤 데이터 건수로 나눠 확률 밀도 함수를 추정

PDF (Probability Density Function)

- 확률 변수의 분포를 나타내는 함수
- 정규분포함수, 감마 분포, t-분포 등

KDE는 개별 관측 데이터에 커널 함수(ex. 가우시안 분포 함수)를 적용한 뒤, 이 적용 값을 모두 더한 후 개별 관측 데이터의 건수로 나눠 확률 밀도 함수를 추정



커널 함수식


$$\text{KDE} = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

K: 커널 함수

x: 확률 변수값

x_i : 관측값

h: 대역폭 → 부드럽거나 뾰족한 형태로 평활화하는 데 적용, 확률 밀도 추정 성능을 크게 좌우



작은 h 값: 좁고 뾰족한 KDE → 변동성이 커 과적합하기 쉬움, 많은 수의 군집 중심점

큰 h 값: 과도하게 평활화된 KDE → 지나치게 단순화되어 과소적합하기 쉬움, 적은 수의 군집 중심점

사이킷런 MeanShift 클래스

- bandwidth: KDE의 대역폭 h
- estimate_bandwidth(): 최적의 대역폭 h 계산

장점: 유연한 군집화 가능, 이상치 영향력 작음, 군집의 개수 정하지 않아도 됨


단점: 수행 시간 오래 걸림, band-width 크기에 따른 군집화 영향도가 매우 큼

▼ 4. GMM (Gaussian Mixture Model)


GMM


- 군집화를 적용하고자 하는 데이터가 여러 개의 가우시안 분포를 가진 데이터 집합들이 섞여서 생성된 것이라는 가정 하에 군집화를 수행하는 방식

가우시안 분포




표준 정규 분포: 평균이 0이고 표준편차가 1






세 개의 정규분포 합치면 이런 형태가 됨



데이터 분포도가 다음과 같으면 이 데이터 세트가 평균 분포 A, B, C가 합쳐진 것임을 알 수 있음



데이터 세트를 구성하는 여러 개의 정규 분포 곡선을 추출하고, 개별 데이터가 이 중 어떤 정규 분포에 속하는지 결정하는 방식


모수 추정

- 개별 정규 분포의 평균과 분산

- 각 데이터가 어떤 정규 분포에 해당되는지의 확률
- EM (Expectation and Maximization) 방법 적용
- 사이킷런 GaussianMixture 클래스

▼ GMM과 K-평균의 비교

KMeans는 원형의 범위에서 군집화 수행



KMeans는 길쭉한 타원형으로 늘어선 경우에 군집화를 잘 수행하지 못함

visualize_cluster_plot(clusterobj, dataframe, label_name, iscluster=True)

- clusterobj: 사이킷런의 군집 수행 객체. KMeans나 GaussianMixture의 fit()와 predict()로 군집화를 완료한 객체. 만약 군집화 결과 시각화가 아니고 make_blobs()로 생성한 데이터의 시각화일 경우 None 입력
- dataframe: 피쳐 데이터 세트와 label 값을 가진 DataFrame
- label_name: 군집화 결과 시각화일 경우 dataframe 내의 군집화 label 컬럼명, make_blobs() 결과 시각화일 경우는 dataframe 내의 target 컬럼명
- iscenter: 사이킷런 Cluster 객체가 군집 중심 좌표를 제공하면 True, 그렇지 않으면 False


유연하게 적용 가능하지만 수행 시간 오래걸림

▼ 5. DBSCAN (Density Based Spatial Clustering of Applications with Noise)

DBSCAN

- 간단하고 직관적인 알고리즘

- 데이터의 분포가 기하학적으로 복잡한 데이터 세트에도 효과적인 군집화 가능



내부의 원 모양과 외부의 원 모양 형태의 분포를 가진 데이터 세트

K 평균, 평균 이동, GMM으로는 효과적인 군집화 수행 어려움

DBSCAN은 특정 공간 내에 데이터 밀도 차이를 기반 알고리즘으로 하고 있어서 복잡한 기하학적 분포도를 가진 데이터 세트에 대해서도 군집화를 잘 수행

파라미터

- 입실론 주변 영역(epsilon): 개별 데이터를 중심으로 입실론 반경을 가지는 원형의 영역
- 최소 데이터 개수(min points): 개별 데이터의 입실론 주변 영역에 포함되는 타 데이터의 개수


데이터 포인트

입실론 주변 영역 내에 포함되는 최소 데이터 개수를 충족시키는지 아닌가에 따라 나뉨


- 핵심 포인트(Core Point): 주변 영역 내에 최소 데이터 개수 이상의 타 데이터를 가지고 있을 경우 해당 데이터를 핵심 포인트라고 합니다.
- 이웃 포인트(Neighbor Point): 주변 영역 내에 위치한 타 데이터를 이웃 포인트라고 합니다.
- 경계 포인트(Border Point): 주변 영역 내에 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않지만 핵심 포인트를 이웃 포인트로 가지고 있는 데이터를 경계 포인트라고 합니다.
- 잡음 포인트(Noise Point): 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않으며, 핵심 포인트도 이웃 포인트로 가지고 있지 않는 데이터를 잡음 포인트라고 합니다.

주요 개념 설명


1. 다음 그림과 같이 P1에서 P12까지 12개의 데이터 세트에 대해서 DBSCAN 군집화를 적용하면서 주요 개념을 설명하겠습니다 특정 입실론 반경 내에 포함될 최소 데이터 세트를 6개로(자기 자신의 데이터를 포함) 가정하겠습니다.




2. P1 데이터를 기준으로 입실론 반경 내에 포함된 데이터가 7개(자신은 P1, 이웃 데이터 P2, P6, P7, P8, P9, P11)로 최소 데이터 5개 이상을 만족하므로 P1 데이터는 핵심 포인트(Core Point)입니다.




3. 다음으로 P2 데이터 포인트를 살펴보겠습니다. P2 역시 반경 내에 6개의 데이터(자신은 P2, 이웃 데이터 P1, P3, P4, P9, P10)를 가지고 있으므로 핵심 포인트입니다.




4. 핵심 포인트 P1의 이웃 데이터 포인트 P2 역시 핵심 포인트일 경우 P1에서 P2로 연결해 직접 접근이 가능합니다.




5. 특정 핵심 포인트에서 직접 접근이 가능한 다른 핵심 포인트를 서로 연결하면서 군집화를 구성합니다. 이러한 방식으로 점차적으로 군집(Cluster) 영역을 확장해 나가는 것이 DBSCAN 군집화 방식입니다.



6. P3 데이터의 경우 반경 내에 포함되는 이웃 데이터는 P2, P4로 2개이므로 군집으로 구분할 수 있는 핵심 포인트가 될 수 없습니다. 하지만 이웃 데이터 중에 핵심 포인트인 P2를 가지고 있습니다. 이처럼 자신은 핵심 포인트가 아니지만, 이웃 데이터로 핵심 포인트를 가지고 있는 데이터를 경계 포인트(Border Point)라고 합니다. 경계 포인트는 군집의 외곽을 형성합니다.



7. 다음 그림의 P5와 같이 반경 내에 최소 데이터를 가지고 있지도 않고, 핵심 포인트 또한 이웃 데이터로 가지고 있지 않는 데이터를 잡음 포인트(Noise Point)라고 합니다.



사이킷런 DBSCAN 클래스

- eps: 입실론 주변 영역의 반경
- min_samples: 핵심 포인트가 되기 위해 입실론 주변 영역 내에 포함돼야 할 데이터의 최소 개수, 자신의 데이터 포함

▼ 6. 군집화 실습 — 고객 세그먼테이션

고객 세그먼테이션

- 다양한 기준으로 고객을 분류하는 기법
- 어떤 상품을 얼마나 많은 비용을 써서 얼마나 자주 사용하는가에 기반한 정보 중요
→ 타겟 마케팅

타겟 마케팅

- 고객을 여러 특성에 맞게 세분화해서 그 유형에 따라 맞춤형 마케팅이나 서비스를 제공

RFM 기법

- Recency: 가장 최근 상품 구입 일에서 오늘까지의 기간
- Frequency: 상품 구매 횟수
- Monetary Value: 총 구매 금액