



파머완 16주차

Chapter 9. 추천 시스템

1. 추천 시스템의 개요와 배경

추천 시스템은 온라인에서 특히 필요 → 선택 부담 해결



- 콘텐츠 기반 필터링
- 협업 필터링
 - 최근접 이웃 협업 필터링
 - 잠재 요인 협업 필터링

2. 콘텐츠 기반 필터링 추천 시스템


콘텐츠 기반 필터링: 사용자가 특정한 아이템을 매우 선호하는 경우, 그 아이템과 비슷한 콘텐츠를 가진 다른 아이템을 추천하는 방식



장르: SF, 드라마, 미스터리
 감독: 드니 빌뇌브
 출연: 에이미 아담스, 제레미 러너
 키워드: 외계인 침공, 예술성, 스릴러 요소



장르: SF, 액션, 스릴러
 감독: 드니 빌뇌브
 출연: 라이언 고슬링, 해리슨 포드
 키워드: 리들리 스콧 감독의 전작을 리메이크



장르: SF, 액션, 스릴러
 감독: 리들리 스콧
 출연: 노미 라마스, 마이클 패스벤더
 키워드: 에일리언 프리퀼, 액션과 스릴러의 조화



사용자 선호 프로필

선호 장르: SF, 액션, 스릴러
 선호 배우: 에이미 아담스, 마이클 패스벤더 등
 선호 감독: 리들리 스콧, 드니 빌뇌브

사용자가 높게 평가한 영화의 장르, 감독, 출연 배우, 키워드 등을 감안해 적절하게 매칭되는 영화를 추천해줌

3. 최근접 이웃 협업 필터링

협업 필터링: 사용자가 아이템에 매긴 평점 정보나 상품 구매 이력과 같은 사용자 행동 양식만을 기반으로 추천을 수행하는 것

- 목표: 사용자-아이템 평점 매트릭스와 같은 축적된 사용자 행동 데이터를 기반으로 사용자가 아직 평가하지 않은 아이템을 예측 평가하는 것
- 최근접 이웃 방식 / 잠재 요인 방식: 모두 사용자-아이템 평점 행렬 데이터에만 의지해 추천 수행
- 행: 개별 사용자, 열: 개별 아이템, 행-열 위치: 평점

로우 레벨 형태의 사용자 - 아이템 평점 데이터

User ID	Item ID	Rating
User 1	Item 1	3
User 1	Item 3	3
User 2	Item 1	4
User 2	Item 2	1
User 3	Item 4	5

변환

사용자 로우, 아이템 칼럼으로 구성된 사용자 -아이템 평점 데이터

	Item 1	Item 2	Item 3	Item 4
User 1	3		3	
User 2	4	1		
User 3				5

- 사용자-아이템 평점 행렬
 - 다차원 행렬
 - 희소 행렬

최근접 이웃 협업 필터링 = 메모리 협업 필터링

- 사용자 기반: 비슷한 고객들이 구매한 상품 제시
- 아이템 기반: 이 상품을 선택한 다른 고객들이 구매한 상품 제시

사용자 기반 최근접 이웃 방식

- 특정 사용자와 유사한 다른 사용자를 Top-N으로 선정해 이 Top-N 사용자가 좋아하는 아이템을 추천

		다크 나이트	인터스텔라	엣지 오브 투모로우	프로메테우스	스타워즈 라스트제다이
상호간 유사도 높음	사용자 A	5	4	4		
	사용자 B	5	3	4	5	3
	사용자 C	4	3	3	2	5

사용자 A는 사용자 C보다 사용자 B와 영화 평점 측면에서 유사도가 높음. 따라서 사용자 A에게는 사용자 B가 재미있게 본 '프로메테우스'를 추천

아이템 기반 최근접 이웃 방식

- 아이템이 가지는 속성과는 상관없이 사용자들이 그 아이템을 좋아하는지/싫어하는지의 평가 척도가 유사한 아이템을 추천하는 기준이 됨
- 사용자 기반 최근접 이웃 데이터 세트와 행과 열이 반대

		사용자 A	사용자 B	사용자 C	사용자 D	사용자 E
상호간 유사도 높음	다크 나이트	5	4	5	5	5
	프로메테우스	5	4	4		5
	스타워즈 라스트제다이	4	3	3		4

여러 사용자들의 평점을 기준으로 볼 때 '다크 나이트'와 가장 유사한 영화는 '프로메테우스'

사용자들의 평점 분포가 비슷한 아이템을 추천

정확도: 아이템 기반 > 사용자 기반

- 비슷한 아이템을 선호한다고 해서 취향이 비슷하다고 판단하기는 어려움


4. 잠재 요인 협업 필터링

잠재 요인 협업 필터링: 사용자-아이템 평점 매트릭스 속에 숨어 있는 잠재 요인을 추출해 추천 예측을 할 수 있게 하는 기법


행렬 분해: 대규모 다차원 행렬을 SVD와 같은 차원 감소 기법으로 분해하는 과정에서 잠재 요인 추출

잠재 요인을 기반으로 다차원 희소 행렬인 사용자-아이템 행렬 데이터를 저차원 밀집 행렬의 사용자-잠재 요인 행렬과 아이템-잠재 요인 행렬의 전치 행렬로 분해할 수 있음

→ 분해된 두 행렬의 내적을 통해 새로운 예측 사용자-아이템 평점 행렬 데이터를 만들어서 사용자가 아직 평점을 부여하지 않는 아이템에 대한 예측 평점 생성




< 행렬 분해를 통한 잠재 요인 협업 필터링 >



- 사용자-아이템 평점 행렬 R
 - $R(u, i)$: 사용자(User)의 아이템(Item)에 대한 평점

- 사용자-잠재 요인 행렬을 사용자의 영화 장르별 선호도 행렬 P로 가정
 - factor 1: 액션 선호도, factor 2: 로맨스 선호도
 - $P(u, k)$ 에서 u 는 사용자 아이디, k 는 잠재 요인 칼럼인 장르별 선호도
- 아이템-잠재 요인 행렬은 영화별로 여러 장르 요소로 구성된 영화의 장르별 요소 행렬 Q로 가정
 - $Q(i, k)$ 에서 i 는 아이템 아이디, k 는 잠재 요인 칼럼인 장르별 요소
- Q와 P의 내적 계산을 위해 Q의 행과 열의 위치를 교환한 Q.T로 변환
- 평점 = 사용자의 장르별 선호도 벡터와 영화의 장르별 특성 벡터의 곱




행렬분해의 이해

행렬 분해: 다차원의 매트릭스를 저차원 매트릭스로 분해하는 기법

- SVD(Singular Vector Decomposition)
- NMF(Non-Negative Matrix Factorization)

M개의 사용자 행과 N개의 아이템 열을 가진 평점 행렬 R: M X N 차원

- 행렬 분해를 통해 사용자-K 차원 잠재 요인 행렬 P(M X K 차원)와 K차원 잠재 요인-아이템 행렬 Q.T(K X N 차원)로 분해될 수 있음



$$R = P * Q.T$$

R(4 X 5)

	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	4			2	
User 2		5		3	
User 3			3	4	4
User 4	5	2	1	2	

P(4 X 2)

	factor 1	factor 2
User 1	0.94	0.96
User 2	2.14	0.08
User 3	1.93	1.79
User 4	0.58	1.59

개별 Row는 개별 User에 대한 Latent Factor들을 반영

Q.T(2 X 4)

	Item 1	Item 2	Item 3	Item 4	Item 5
factor 1	1.7	2.3	1.41	1.36	0.41
factor 2	2.49	0.41	0.14	0.75	1.77

개별 Column은 개별 item에 대한 Latent Factor들을 반영

$\approx$

행렬 내에 null 값을 많이 가지는 고차원의 희소 행렬인 R 행렬은 저차원 밀집 행렬인 P 행렬과 Q 행렬로 분해될 수 있음

$$r_{u,i} = p_u * q_i^t$$

- $r(u, i)$ = 평점데이터
- p_u = u행 사용자의 벡터
- q_i^t = Q 행렬의 i행 아이템 벡터의 전치 벡터

r(2, 4)

	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	4				
User 2				3	
User 3			3	4	4
User 4	5	2	1	2	

p₂

	factor 1	factor 2
User 1	0.94	0.96
User 2	2.14	0.08
User 3	1.93	1.79
User 4	0.58	1.59

q₄^t


	Item 1	Item 2	Item 3	Item 4	Item 5
factor 1	1.7	2.3	1.41	1.36	0.41
factor 2	2.49	0.41	0.14	0.75	1.77

$\approx$

$\hat{r} = 2.14 * 1.36 + 0.08 * 0.75 = 2.97$

사용자-아이템 평점 행렬의 미정 값을 포함한 모든 평점 값은 행렬 분해를 통해 얻어진 P 행렬과 Q.T 행렬의 내적을 통해 예측 평점으로 다시 계산 가능

$$R \cong \hat{R} = P * Q.T$$



R 행렬을 P와 Q 행렬로 분해할 때 SVD 방식 이용

null 값이 있을 때는 확률적 경사 하강법이나 ALS 방식을 이용해 SVD 수행

확률적 경사 하강법을 이용한 행렬 분해

P와 Q 행렬로 계산된 예측 R 행렬 값이 실제 R 행렬 값과 가장 최소의 오류를 가질 수 있도록 반복적인 비용 함수 최적화를 통해 P와 Q를 유추해내는 것

1. P와 Q를 임의의 값을 가진 행렬로 설정합니다.
2. P와 Q.T 값을 곱해 예측 R 행렬을 계산하고 예측 R 행렬과 실제 R 행렬에 해당하는 오류 값을 계산합니다.
3. 이 오류 값을 최소화할 수 있도록 P와 Q 행렬을 적절한 값으로 각각 업데이트합니다.
4. 만족할 만한 오류 값을 가질 때까지 2, 3번 작업을 반복하면서 P와 Q 값을 업데이트해 근사화합니다.

실제 값과 예측값의 오류 최소화와 L2 규제를 고려한 비용 함수식

$$\min \sum (r_{(u,i)} - p_u q_i^t)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

비용 함수를 최소화하기 위해서 새롭게 업데이트되는 p'_u 와 q'_i

$$p'_u = p_u + \eta (e_{(u,i)} * q_i - \lambda * p_u)$$

$$q'_i = q_i + \eta (e_{(u,i)} * p_u - \lambda * q_i)$$

- p_u : P 행렬의 사용자 u 행 벡터
- q_i^t : Q 행렬의 아이템 i 행의 전치 벡터(transpose vector)
- $r_{u,i}$: 실제 R 행렬의 u 행, i 열에 위치한 값
- $\hat{r}_{u,i}$: 예측 $\hat{R}$ 행렬의 u 행, i 열에 위치한 값. $p_u * q_i^t$ 로 계산
- $e_{(u,i)}$: u 행, i 열에 위치한 실제 행렬 값과 예측 행렬 값의 차이 오류. $r_{u,i} - \hat{r}_{u,i}$ 로 계산
- η : SGD 학습률
- λ : L2 규제(Regularization) 계수

SGD 기반의 행렬분해: L2 규제를 반영해 실제 R 행렬 값과 예측 R 행렬 값의 차이를 최소화 하는 방향성을 가지고 P행렬과 Q행렬에 업데이트 값을 반복적으로 수행하면서 최적화된 예측 R 행렬을 구하는 방식

8. 파이썬 추천 시스템 패키지 — Surprise

Surprise 패키지의 장점

- 다양한 추천 알고리즘: 사용자 또는 아이템 기반 최근접 이웃 협업 필터링, SVD, SVD++, NMF 기반의 잠재 요인 협업 필터링
- 사이킷런의 핵심 API와 유사한 API명으로 작성됨

Surprise 주요 모듈 소개

Dataset

Surprise는 user_id, item_id, rating 데이터가 로우 레벨로 된 데이터 세트만 적용할 수 있음

API 명	내용
Dataset.load_builtin (name='ml-100k')	무비렌즈 아카이브 FTP 서버에서 무비렌즈 데이터를 내려받습니다. ml-100k, ml-1M를 내려받을 수 있습니다. 일단 내려받은 데이터는 .surprise_data 디렉터리 밑에 저장되고, 해당 디렉터리에 데이터가 있으면 FTP에서 내려받지 않고 해당 데이터를 이용합니다. 입력 파라미터인 name으로 대상 데이터가 ml-100k인지 ml-1m인지를 입력합니다(name='ml-100k'). 디폴트는 ml-100k입니다.

API 명	내용
Dataset.load_from_file (file_path, reader)	OS 파일에서 데이터를 로딩할 때 사용합니다. coma, 탭 등으로 칼럼이 분리된 포맷의 OS 파일에서 데이터를 로딩합니다. 입력 파라미터로 OS 파일명, Reader로 파일의 포맷을 지정합니다.
Dataset.load_from_df (df, reader)	판다스의 DataFrame에서 데이터를 로딩합니다. 파라미터로 DataFrame을 입력받으며 DataFrame 역시 반드시 3개의 칼럼 인 사용자 아이디, 아이템 아이디, 평점 순으로 칼럼 순서가 정해져 있어야 합니 다. 입력 파라미터로 DataFrame 객체, Reader로 파일의 포맷을 지정합니다.

Surprise 추천 알고리즘 클래스

- SVD: 행렬 분해를 통한 잠재 요인 협업 필터링을 위한 SVD 알고리즘
- KNNBasic: 최근접 이웃 협업 필터링을 위한 KNN 알고리즘
- BaselineOnly: 사용자 Bias와 아이템 Bias를 감안한 SGD 베이스라인 알고리즘

SVD 클래스 입력 파라미터

파라미터명	내용
n_factors	잠재 요인 K의 개수. 디폴트는 100, 커질수록 정확도가 높아질 수 있으나 과적합 문제가 발생할 수 있습니다.
n_epochs	SGD(Stochastic Gradient Descent) 수행 시 반복 횟수. 디폴트는 20.
biased (bool)	베이스라인 사용자 편향 적용 여부이며, 디폴트는 True입니다.

베이스라인 평점

베이스라인 평점: 개인의 성향을 반영해 아이템 평가에 편향성 요소를 반영하여 평점을 부과하는 것

베이스라인 평점 = 전체 평균 평점 + 사용자 편향 점수 + 아이템 편향 점수

- 전체 평균 평점: 모든 사용자의 아이템에 대한 평점을 평균한 값
- 사용자 편향 점수: 사용자별 아이템 평점 평균 값 - 전체 평균 평점
- 아이템 편향 점수: 아이템별 평점 평균 값 - 전체 평균 평점



모든 사용자의 평균 영화 평점 : **3.5**



난 진정한 영화 매니아.
영화 평가는 언제나 간간하게

사용자 A 평균 평점
3.0

사용자 A의 어벤저스 3편 베이스 라인 평점 = $3.5 - 0.5 + 0.7 = 3.7$

모든 사용자의
평균 영화 평점

3.5



사용자 편향 점수

$3.0 - 3.5 = -0.5$



아이템 편향 점수

$4.2 - 3.5 = 0.7$

어벤저스 3편 평균 평점
4.2

